

# OPTIMIZACIÓN

Primer Cuatrimestre 2023

---

## Trabajo Práctico N° 1: Regularización del modelo lineal

La regresión lineal es un modelo para una variable continua  $Y$  como respuesta de otras características o covariables que denotaremos  $X_1, X_2, \dots, X_p \in \mathbb{R}$ . La relación viene dada por la fórmula:

$$Y = \sum_{j=1}^p \beta_j X_j + \varepsilon,$$

donde  $\varepsilon$  es un término del error que no depende de las covariables y  $\beta_1, \beta_2, \dots, \beta_p \in \mathbb{R}$  son parámetros desconocidos.

Dadas  $n$  observaciones  $x^{(1)}, \dots, x^{(n)} \in \mathbb{R}^p$ , donde  $x_j^{(i)}$  representa la  $j$ -ésima característica de la observación  $i$  y sus respectivas respuestas  $y_1, \dots, y_n \in \mathbb{R}$ , se intentará estimar los valores de los parámetros desconocidos. Los criterios usados para determinarlos serán de tal forma que minimicen cierta función que evalúa el desajuste de predecir  $Y$  como  $\sum_{j=1}^p \beta_j X_j$ .

### Estimador de mínimos cuadrados.

Se busca  $\beta \in \mathbb{R}^p$  que minimice la suma residual de cuadrados:

$$f(\beta) = \sum_{i=1}^n \left( y_i - \sum_{j=1}^p \beta_j x_j^{(i)} \right)^2,$$

con  $\hat{\beta}$  aquel que minimiza a  $f$ .

**Ejercicio 1** Calcular su gradiente y matriz hessiana.

**Ejercicio 2** Se define la matriz de diseño  $X \in \mathbb{R}^{n \times p}$  como  $X_{ij} = x_j^{(i)}$ , es decir, la fila  $i$  representa la observación  $i$ . Escribir la matriz hessiana en términos de la matriz  $X$  y concluir que  $f$  resulta convexa en  $\mathbb{R}^p$ .

**Ejercicio 3** Se considera el modelo lineal dado por

$$Y = X_1 + 3X_2 + 5X_3 - 2X_4 + 4X_5 + 9X_6 - 3X_7 + \varepsilon$$

y los archivos `datos1_tp.csv` y `datos2_tp.csv` que contienen 100 observaciones, cada los valores de sus variables explicativas y su respectiva respuesta obtenidas de ese modelo. Para cada tanda de datos, estimar los parámetros  $\beta$  mediante mínimos cuadrados usando el método de descenso por el gradiente combinado con alguna búsqueda lineal. Calcular la cantidad de iteraciones y el error en norma 2 entre  $\beta$  y  $\hat{\beta}$  para cada uno y explicar porque difiere dicha cantidad para cada tanda de datos.

**Regresión Ridge.**

Sea  $\alpha > 0$ , se busca  $\beta \in \mathbb{R}^p$  que minimice la siguiente expresión:

$$f_R(\beta) = \sum_{i=1}^n \left( y_i - \sum_{j=1}^p \beta_j x_j^{(i)} \right)^2 + \alpha \sum_{j=1}^p \beta_j^2,$$

con  $\hat{\beta}_\alpha$  aquel que minimiza a  $f$ .

**Ejercicio 4** Calcular su gradiente y matriz hessiana.

**Ejercicio 5** Expresar el número de condición de la matriz hessiana de  $f_R$  en términos de los autovalores de la de  $f$ . ¿Qué sucede cuando  $\alpha \rightarrow +\infty$ ?

**Ejercicio 6** Para cada tanda de datos y para cada  $\alpha$ , estimar los parámetros  $\beta$  minimizando la función de Ridge mediante el método de descenso por el gradiente combinado con la misma búsqueda lineal anterior. Graficar el error en norma 2 entre  $\beta$  y  $\hat{\beta}_\alpha$  en función de  $\alpha$  y la cantidad de iteraciones en función de  $\alpha$ . Explicar el comportamiento del gráfico de la iteraciones.